



고객을 세그멘테이션하자 [프로젝트] - 유정하

11-2. 데이터 불러오기

데이터 살펴보기

- 테이블에 있는 10개의 행만 출력하기

```
select *  
from `modulabs_project.data`  
limit 10;
```

행	InvoiceNo	StockCode	Description	Quantity	InvoiceDate	UnitPrice	CustomerID	Country
1	536365	85123A	WHITE HANGING HEART T-LIG...	6	2010-12-01 08:26:00 UTC	2.55	17850	United Kingdom
2	536365	71053	WHITE METAL LANTERN	6	2010-12-01 08:26:00 UTC	3.39	17850	United Kingdom
3	536365	844068	CREAM CUPID HEARTS COAT H...	8	2010-12-01 08:26:00 UTC	2.75	17850	United Kingdom
4	536365	84029G	KNITTED UNION FLAG HOT WA...	6	2010-12-01 08:26:00 UTC	3.39	17850	United Kingdom
5	536365	84029E	RED WOOLLY HOTTIE WHITE H...	6	2010-12-01 08:26:00 UTC	3.39	17850	United Kingdom
6	536365	22752	SET 7 BABUSHKA NESTING BO...	2	2010-12-01 08:26:00 UTC	7.65	17850	United Kingdom
7	536365	21730	GLASS STAR FROSTED T-LIGHT...	6	2010-12-01 08:26:00 UTC	4.25	17850	United Kingdom
8	536365	22833	HAND WARMER UNION JACK	6	2010-12-01 08:28:00 UTC	1.85	17850	United Kingdom

- 전체 데이터는 몇 행으로 구성되어 있는지 확인하기

```
select count(*)  
from `modulabs_project.data`;
```

행	f0_
1	541909

데이터 수 세기

- COUNT 함수를 사용해서, 각 컬럼별 데이터 포인트의 수를 세어 보기

```
select  
  count(InvoiceNo),  
  count(StockCode),  
  count(Description),  
  count(Quantity),  
  count(InvoiceDate),  
  count(UnitPrice),  
  count(CustomerID),  
  count(Country)  
from `modulabs_project.data`;
```

행	f0_	f1_	f2_	f3_	f4_	f5_	f6_	f7_
1	541909	541909	540455	541909	541909	541909	406829	541909

11-4. 데이터 전처리 방법(1): 결측치 제거

컬럼 별 누락된 값의 비율 계산

- 각 컬럼 별 누락된 값의 비율을 계산
 - 각 컬럼에 대해서 누락 값을 계산한 후, 계산된 누락 값을 UNION ALL을 통해 합치기

```

SELECT
  'InvoiceNo' AS column_name,
  ROUND(SUM(CASE WHEN InvoiceNo IS NULL THEN 1 ELSE 0 END) / COUNT(*) * 100, 2) AS missing_percentage
FROM `modulabs_project.data`

UNION ALL
SELECT
  'StockCode',
  ROUND(SUM(CASE WHEN StockCode IS NULL THEN 1 ELSE 0 END) / COUNT(*) * 100, 2)
FROM `modulabs_project.data`

UNION ALL
SELECT
  'Description',
  ROUND(SUM(CASE WHEN Description IS NULL THEN 1 ELSE 0 END) / COUNT(*) * 100, 2)
FROM `modulabs_project.data`

UNION ALL
SELECT
  'Quantity',
  ROUND(SUM(CASE WHEN Quantity IS NULL THEN 1 ELSE 0 END) / COUNT(*) * 100, 2)
FROM `modulabs_project.data`

UNION ALL
SELECT
  'InvoiceDate',
  ROUND(SUM(CASE WHEN InvoiceDate IS NULL THEN 1 ELSE 0 END) / COUNT(*) * 100, 2)
FROM `modulabs_project.data`

UNION ALL
SELECT
  'UnitPrice',
  ROUND(SUM(CASE WHEN UnitPrice IS NULL THEN 1 ELSE 0 END) / COUNT(*) * 100, 2)
FROM `modulabs_project.data`

UNION ALL
SELECT
  'CustomerID',
  ROUND(SUM(CASE WHEN CustomerID IS NULL THEN 1 ELSE 0 END) / COUNT(*) * 100, 2)
FROM `modulabs_project.data`

UNION ALL
SELECT
  'Country',
  ROUND(SUM(CASE WHEN Country IS NULL THEN 1 ELSE 0 END) / COUNT(*) * 100, 2)
FROM `modulabs_project.data`;

```

행	column_name ▼	missing_percenta...
1	InvoiceNo	0.0
2	StockCode	0.0
3	Description	0.27
4	Quantity	0.0
5	InvoiceDate	0.0
6	UnitPrice	0.0
7	CustomerID	24.93
8	Country	0.0

결측치 처리 전략

- `StockCode = '85123A'` 의 `Description` 을 추출하는 쿼리문을 작성하기

```
SELECT distinct description
FROM project_name.modulabs_project.data
where stockcode = '85123A';
```

행	description
1	WHITE HANGING HEART T-LIG...
2	?
3	wrongly marked carton 22804
4	CREAM HANGING HEART T-LIG...

결측치 처리

- **DELETE** 구문을 사용하며, **WHERE** 절을 통해 데이터를 제거할 조건을 제시

```
delete from `modulabs_project.data`
where customerid is null or description is null;
```

쿼리 결과	
작업 정보	결과
이 문으로 data의 행 135,080개가 삭제되었습니다.	

11-5. 데이터 전처리(2): 중복값 처리

중복값 확인

- 중복된 행의 수를 세어보기
 - 8개의 컬럼에 그룹 함수를 적용한 후, **COUNT**가 1보다 큰 데이터를 세어보기

```
SELECT
    SUM(cnt - 1) AS duplicated_rows
FROM (
    SELECT
        InvoiceNo,
        StockCode,
        Description,
        Quantity,
        InvoiceDate,
        UnitPrice,
        CustomerID,
        Country,
        COUNT(*) AS cnt
    FROM `modulabs_project.data`
    GROUP BY
        InvoiceNo,
        StockCode,
        Description,
        Quantity,
```

```
InvoiceDate,
UnitPrice,
CustomerID,
Country
HAVING cnt > 1
);
```

행	duplicated_rows
1	5225

중복값 처리

- 중복값을 제거하는 쿼리문 작성하기
 - CREATE OR REPLACE TABLE** 구문을 활용하여 모든 컬럼(*)을 **DISTINCT** 한 데이터로 업데이트

```
create or replace table `modulabs_project.data` as
select distinct *
from `modulabs_project.data`;
```

행	before_cnt	after_cnt
1	406829	401604

11-6. 데이터 전처리(3): 오류값 처리

InvoiceNo 살펴보기

- 고유(unique)한 **InvoiceNo**의 개수를 출력하기

```
select
count(distinct invoiceno)
from `modulabs_project.data`;
```

행	f0_
1	22190

- 고유한 **InvoiceNo**를 앞에서부터 100개를 출력하기

```
select distinct invoiceno
from `modulabs_project.data`
limit 100;
```

행	invoiceno
1	541431
2	C541433
3	537626
4	542237
5	549222
6	556201
7	562032
8	573511
9	581180

(말에 더 있음)

- **InvoiceNo** 가 'C'로 시작하는 행을 필터링 할 수 있는 쿼리문을 작성하기 (100행까지만 출력)

```
select *
from `modulabs_project.data`
where invoiceno like 'C%'
limit 100;
```

행	InvoiceNo	StockCode	Description	Quantity	InvoiceDate	UnitPrice	CustomerID	Country
1	C541433	23166	MEDIUM CERAMIC TOP STORA...	-74215	2011-01-18 10:17:00 UTC	1.04	12346	United Kingdom
2	C545329	M	Manual	-1	2011-03-01 15:47:00 UTC	183.75	12352	Norway
3	C545329	M	Manual	-1	2011-03-01 15:47:00 UTC	280.05	12352	Norway
4	C545330	M	Manual	-1	2011-03-01 15:49:00 UTC	376.5	12352	Norway
5	C547388	21914	BLUE HARMONICA IN BOX	-12	2011-03-22 16:07:00 UTC	1.25	12352	Norway
6	C547388	22784	LANTERN CREAM GAZEBO	-3	2011-03-22 16:07:00 UTC	4.95	12352	Norway
7	C547388	22413	METAL SIGN TAKE IT OR LEAVE...	-6	2011-03-22 16:07:00 UTC	2.95	12352	Norway
8	C547388	37448	CERAMIC CAKE DESIGN SPOTT...	-12	2011-03-22 16:07:00 UTC	1.49	12352	Norway

- 구매 건 상태가 **Canceled** 인 데이터의 비율(%) - 소수점 첫번째 자리까지

```
select
round(
sum(case when invoiceno like 'C%' then 1 else 0 end)
/ count(*)
* 100,
1)
from `modulabs_project.data`;
```

행	f0_
1	2.2

StockCode 살펴보기

- 고유한 **StockCode** 의 개수를 출력하기

```
select count(distinct stockcode)
from `modulabs_project.data`;
```

행	f0_
1	3684

- 어떤 제품이 가장 많이 판매되었는지 보기 위하여 **StockCode** 별 등장 빈도를 출력하기
 - 상위 10개의 제품들을 출력하기

```
select
  stockcode,
  count(*) as sell_cnt
from `modulabs_project.data`
group by StockCode
order by sell_cnt desc
limit 10;
```

행	stockcode	sell_cnt
1	85123A	2065
2	22423	1894
3	85099B	1659
4	47566	1409
5	84879	1405
6	20725	1346
7	22720	1224
8	POST	1196
9	22197	1110

- **StockCode**의 컬럼에 있던 값 중에서 숫자를 제외한 문자만 남기고 문자가 몇 자리 수 인지 세고
 - 숫자가 0~1개인 값들에는 어떤 코드들이 들어가 있는지 출력하기

```
select distinct stockcode, number_count
from (
  select
    stockcode,
    length(stockcode)
      - length(regexp_replace(stockcode, r'[0-9]', '')) as number_count
  from `modulabs_project.data`
)
where number_count <= 1
order by number_count;
```

행	stockcode	number_count
1	POST	0
2	M	0
3	D	0
4	BANK CHARGES	0
5	PADS	0
6	DOT	0
7	CRUK	0
8	C2	1

- **StockCode**의 컬럼에 있던 값 중에서 숫자를 제외한 문자만 남기고 문자가 몇 자리 수 인지 세고
 - 숫자가 0~1개인 값들을 가지고 있는 데이터 수는 전체 데이터 수 대비 몇 퍼센트인지 구하기 (소수점 두 번째 자리까지)

```
with StockCodeCounts as (
  select
    stockcode,
    length(stockcode)
      - length(regexp_replace(stockcode, r'[0-9]', ''))
  from `modulabs_project.data`
)
select
  round(
    (select count(*) from stockcodecounts where number_count <= 1)
    /
    (select count(*) from stockcodecounts)
```

```
* 100,
2
);
```

행	f0_
1	0.48

- 제품과 관련되지 않은 거래 기록을 제거하기

```
delete from `modulabs_project.data`
where stockcode in (
  select distinct stockcode
  from (
    select
      stockcode,
      length(stockcode)
      - length(regexp_replace(stockcode, r'[0-9]', '')) as number_count
    from `modulabs_project.data`
  )
  where number_count <= 1
);
```

i 이 문으로 data의 행 1,915개가 삭제되었습니다.

Description 살펴보기

- 고유한 Description 별 출현 빈도를 계산하고 상위 30개를 출력하기

```
select
  description,
  count(*) as description_cnt
from
  `modulabs_project.data`
group by
  description
order by
  description_cnt desc
limit 30;
```

행	description	description_cnt
1	WHITE HANGING HEART T-LIG...	2058
2	REGENCY CAKESTAND 3 TIER	1894
3	JUMBO BAG RED RETROSPOT	1659
4	PARTY BUNTING	1409
5	ASSORTED COLOUR BIRD ORN...	1405
6	LUNCH BAG RED RETROSPOT	1345
7	SET OF 3 CAKE TINS PANTRY D...	1224
8	LUNCH BAG BLACK SKULL	1099
9	PACK OF 72 RETROSPOT CAKE...	1062

- 서비스 관련 정보를 포함하는 행들을 제거하기

```
delete
from `modulabs_project.data`
where description in (
  'High Resolution Image',
  'Next Day Carriage'
);
```

i 이 문으로 data의 행 83개가 삭제되었습니다.

```
description
BAG 250g SWIRLY MARBLES
3 TRADITIONAL BISCUIT CUTTERS SET
BAG 125g SWIRLY MARBLES
POLYESTER FILLER PAD 30CMx30CM
BAG 500g SWIRLY MARBLES
POLYESTER FILLER PAD 45x45cm
POLYESTER FILLER PAD 40x40cm
ESSENTIAL BALM 3.5g TIN IN ENVELOPE
FRENCH BLUE METAL DOOR SIGN No
POLYESTER FILLER PAD 45x30cm
NUMBER TILE VINTAGE FONT No
NUMBER TILE COTTAGE GARDEN No
POLYESTER FILLER PAD 65CMx65CM
FLOWERS HANDBAG blue and orange
"FOLK ART GREETING CARD,pack/12"
THE KING GIFT BAG 25x24x12cm
POLYESTER FILLER PAD 60x40cm
```

- 대소문자를 혼합하고 있는 데이터를 대문자로 표준화 하기

```
create or replace table `modulabs_project.data` as
select
  * except(description),
  upper(description) as Description
from `modulabs_project.data`;
```

```
select distinct description
from `modulabs_project.data`
where regexp_contains(description, r'[a-z]');
```

를 실행했을 때

i 표시할 데이터가 없습니다.

UnitPrice 살펴보기

- UnitPrice 의 최솟값, 최댓값, 평균을 구하기

```
select
  min(unitprice) as min_price,
  max(unitprice) as max_price,
  avg(unitprice) as avg_price
from `modulabs_project.data`;
```


행	min_price	max_price	avg_price
1	0.0	649.5	2.904956757405...

- 단가가 0원인 거래의 개수, 구매 수량(Quantity)의 최솟값, 최댓값, 평균 구하기

```
select
  count(*) as cnt_quantity,
  min(quantity) as min_quantity,
  max(quantity) as max_quantity,
  avg(quantity) as avg_quantity
from `modulabs_project.data`
where unitprice = 0;
```

행	cnt_quantity	min_quantity	max_quantity	avg_quantity
1	33	1	12540	420.5151515151...

- UnitPrice = 0 를 제거하고 일관된 데이터셋을 유지하기

```
create or replace table `modulabs_project.data` as
select *
from `modulabs_project.data`
where unitprice > 0;
```

```
select
  count(*) as cnt_quantity
from `modulabs_project.data`
where unitprice = 0;
```

를 실행했을 때

행	cnt_quantity
1	0

11-7. RFM 스코어

Recency

- InvoiceDate 컬럼을 연월일 자료형으로 변경하기

```
select
  date(invoicedate) as invoiceday,
  *
from `modulabs_project.data`;
```

행	invoiceday	InvoiceNo
1	2011-01-18	541431
2	2011-01-18	C541433
3	2010-12-07	537626
4	2010-12-07	537626
5	2010-12-07	537626
6	2010-12-07	537626
7	2010-12-07	537626
8	2010-12-07	537626

- 가장 최근 구매 일자를 MAX() 함수로 찾아보기

```
SELECT
  (SELECT MAX(InvoiceDate)) FROM `modulabs_project.data`) AS most_recent_date,
  DATE(InvoiceDate) AS InvoiceDay,
  *
FROM `modulabs_project.data`;
```

행	most_recent_date	InvoiceDay
1	2011-12-09	2011-01-18
2	2011-12-09	2011-01-18
3	2011-12-09	2010-12-07
4	2011-12-09	2010-12-07
5	2011-12-09	2010-12-07
6	2011-12-09	2010-12-07
7	2011-12-09	2010-12-07
8	2011-12-09	2010-12-07

- 유저 별로 가장 큰 InvoiceDay를 찾아서 가장 최근 구매일로 저장하기

```
select
  customerid,
  max(date(invoicedate)) as invoiceday
from `modulabs_project.data`
group by customerid;
```

행	customerid	invoiceday
1	12346	2011-01-18
2	12347	2011-12-07
3	12348	2011-09-25
4	12349	2011-11-21
5	12350	2011-02-02
6	12352	2011-11-03
7	12353	2011-05-19
8	12354	2011-04-21
9	12355	2011-05-09

- 가장 최근 일자(most_recent_date)와 유저별 마지막 구매일(InvoiceDay)간의 차이를 계산하기

```
SELECT
  CustomerID,
  EXTRACT(DAY FROM MAX(InvoiceDay) OVER () - InvoiceDay) AS recency
FROM (
  SELECT
    CustomerID,
    MAX(InvoiceDate) AS InvoiceDay
  FROM project_name.modulabs_project.data
  GROUP BY CustomerID
);
```

행	CustomerID	recency
1	12473	53
2	12508	26
3	12530	59
4	12659	29
5	12676	24
6	12752	81
7	12943	301

- 최종 데이터 셋에 필요한 데이터들을 각각 정제해서 이어붙이고 지금까지의 결과를 `user_r` 이라는 이름의 테이블로 저장하기

```
create or replace table `modulabs_project.user_r` as
SELECT
  CustomerID,
  EXTRACT(DAY FROM MAX(InvoiceDay) OVER () - InvoiceDay) AS recency
FROM (
  SELECT
    CustomerID,
    MAX(DATE(InvoiceDate)) AS InvoiceDay
  FROM `modulabs_project.data`
  GROUP BY CustomerID
);
```

행	CustomerID	recency
1	16626	0
2	12518	0
3	15311	0
4	12680	0
5	14446	0
6	16705	0
7	17428	0
8	16446	0
9	17581	0

Frequency

- 고객마다 고유한 InvoiceNo의 수를 세어보기

```
select
  customerid,
  count(distinct invoiceno) as purchase_cnt
from `modulabs_project.data`
group by customerid;
```

행	customerid	purchase_cnt
1	12346	2
2	12347	7
3	12348	4
4	12349	1
5	12350	1
6	12352	8
7	12353	1
8	12354	1
9	12355	1

- 각 고객 별로 구매한 아이템의 총 수량 더하기

```
select
  customerid,
  sum(quantity) as item_cnt
from `modulabs_project.data`
group by customerid;
```

행	customerid	item_cnt
1	12346	0
2	12347	2458
3	12348	2332
4	12349	630
5	12350	196
6	12352	463
7	12353	20
8	12354	530
9	12355	240

- 전체 거래 건수 계산과 구매한 아이템의 총 수량 계산의 결과를 합쳐서 `user_rf` 라는 이름의 테이블에 저장하기

```
create or replace table `modulabs_project.user_rf` as
with purchase_cnt as (
  select
    customerid,
    count(distinct invoiceno) as purchase_cnt
  from `modulabs_project.data`
  group by customerid
),
item_cnt as (
  select
    customerid,
    sum(quantity) as item_cnt
  from `modulabs_project.data`
  group by customerid
)

select
  pc.customerid,
  pc.purchase_cnt,
  ic.item_cnt,
  ur.recency
from purchase_cnt as pc
join item_cnt as ic
```

```
on pc.customerid = ic.customerid
join `modulabs_project.user_r` as ur
on pc.customerid = ur.customerid;
```

이 문으로 이름이 user_rf인 새 테이블이 생성되었습니다.

행	customerid	purchase_cnt	item_cnt	recency
1	12713	1	505	0
2	15520	1	314	1
3	14569	1	79	1
4	13436	1	76	1
5	13298	1	96	1
6	15471	1	256	2
7	14204	1	72	2
8	15195	1	1404	2
9	17914	1	457	3

Monetary

- 고객별 총 지출액 계산 (소수점 첫째 자리에서 반올림)

```
select
  customerid,
  round(sum(quantity * unitprice), 1) as user_total
from `modulabs_project.data`
group by customerid;
```

행	customerid	user_total
1	12346	0.0
2	12347	4310.0
3	12348	1437.2
4	12349	1457.5
5	12350	294.4
6	12352	1265.4
7	12353	89.0
8	12354	1079.4
9	12355	459.4

- 고객별 평균 거래 금액 계산

- 고객별 평균 거래 금액을 구하기 위해 1) `data` 테이블을 `user_rf` 테이블과 조인(LEFT JOIN) 한 후, 2) `purchase_cnt`로 나누어서 3) `user_rfm` 테이블로 저장하기

```
create or replace table `modulabs_project.user_rfm` as
select
  rf.customerid as CustomerID,
  rf.purchase_cnt,
  rf.item_cnt,
  rf.recency,
  ut.user_total,
  round(ut.user_total / rf.purchase_cnt, 0) as user_average
from `modulabs_project.user_rf` rf
left join (
  select
```

```
customerid,
round(sum(quantity * unitprice), 0) as user_total
from `modulabs_project.data`
group by customerid
) ut
on rf.customerid = ut.customerid;
```

행	CustomerID	purchase_cnt	item_cnt	recency	user_total	user_average
1	12713	1	505	0	795.0	795.0
2	14569	1	79	1	227.0	227.0
3	15520	1	314	1	343.0	343.0
4	13436	1	76	1	197.0	197.0
5	13298	1	96	1	360.0	360.0
6	14204	1	72	2	151.0	151.0
7	15195	1	1404	2	3861.0	3861.0
8	15471	1	256	2	454.0	454.0
9	12478	1	233	3	546.0	546.0

RFM 통합 테이블 출력하기

- 최종 user_rfm 테이블을 출력하기

```
select *
from `modulabs_project.user_rfm`;
```

행	CustomerID	purchase_cnt	item_cnt	recency	user_total	user_average
1	12713	1	505	0	795.0	795.0
2	14569	1	79	1	227.0	227.0
3	15520	1	314	1	343.0	343.0
4	13436	1	76	1	197.0	197.0
5	13298	1	96	1	360.0	360.0
6	14204	1	72	2	151.0	151.0
7	15195	1	1404	2	3861.0	3861.0
8	15471	1	256	2	454.0	454.0
9	12478	1	233	3	546.0	546.0

11-8. 추가 Feature 추출

1. 구매하는 제품의 다양성

- 1) 고객 별로 구매한 상품들의 고유한 수를 계산하기
- 2) user_rfm 테이블과 결과를 합치기
- 3) user_data 라는 이름의 테이블에 저장하기

```
create or replace table modu-480005.modulabs_project.user_data as
with unique_products as (
select
customerID,
count(distinct stockcode) as unique_products
from `modulabs_project.data`
group by customerid
)
select ur.*, up.* except (customerid)
from `modulabs_project.user_rfm` as ur
```

```
join unique_products as up
on ur.CustomerID = up.customerid;
```

행	CustomerID	purchase_cnt	item_cnt	recency	user_total	user_average	unique_prod...
1	16061	1	-1	269	-30.0	-30.0	1
2	17925	1	72	372	244.0	244.0	1
3	15118	1	1440	134	245.0	245.0	1
4	17331	1	16	123	175.0	175.0	1
5	15657	1	24	22	30.0	30.0	1
6	16454	1	2	64	6.0	6.0	1
7	17382	1	24	65	50.0	50.0	1
8	13185	1	12	267	71.0	71.0	1
9	16737	1	288	53	418.0	418.0	1

2. 평균 구매 주기

- 고객들의 쇼핑 패턴을 이해하는 것을 목표 (고객 별 재방문 주기 살펴보기)
 - 균 구매 소요 일수를 계산하고, 그 결과를 `user_data` 에 통합

```
CREATE OR REPLACE TABLE modulabs_project.user_data AS
WITH purchase_intervals AS (
  -- (2) 고객 별 구매와 구매 사이의 평균 소요 일수
  SELECT
    CustomerID,
    CASE WHEN ROUND(AVG(interval_), 2) IS NULL THEN 0 ELSE ROUND(AVG(interval_), 2) END AS average_interval
  FROM (
    -- (1) 구매와 구매 사이에 소요된 일수
    SELECT
      CustomerID,
      DATE_DIFF(InvoiceDate, LAG(InvoiceDate) OVER (PARTITION BY CustomerID ORDER BY InvoiceDate), DAY) AS interval_
    FROM
      modulabs_project.data
    WHERE CustomerID IS NOT NULL
  )
  GROUP BY CustomerID
)

SELECT u.*, pi.* EXCEPT (CustomerID)
FROM modulabs_project.user_data AS u
LEFT JOIN purchase_intervals AS pi
ON u.CustomerID = pi.CustomerID;
```

행	CustomerID	purchase_cnt	item_cnt	recency	user_total	user_average	unique_prod...	average_inter...
1	16323	1	50	196	208.0	208.0	1	0.0
2	14424	1	48	17	322.0	322.0	1	0.0
3	14119	1	-2	354	-20.0	-20.0	1	0.0
4	16061	1	-1	269	-30.0	-30.0	1	0.0
5	14576	1	12	372	35.0	35.0	1	0.0
6	17715	1	384	200	326.0	326.0	1	0.0
7	13017	1	48	7	204.0	204.0	1	0.0
8	16953	1	10	30	21.0	21.0	1	0.0
9	12814	1	48	101	86.0	86.0	1	0.0

3. 구매 취소 경향성

- 고객의 취소 패턴 파악하기

- 1) 취소 빈도(cancel_frequency) : 고객 별로 취소한 거래의 총 횟수
- 2) 취소 비율(cancel_rate) : 각 고객이 한 모든 거래 중에서 취소를 한 거래의 비율
 - 취소 빈도와 취소 비율을 계산하고 그 결과를 **user_data** 에 통합하기
(취소 비율은 소수점 두번째 자리)

```
CREATE OR REPLACE TABLE `modulabs_project.user_data` AS

WITH TransactionInfo AS (
  SELECT
    CustomerID,
    COUNT(*) AS total_transactions,
    COUNTIF(InvoiceNo LIKE 'C%') AS cancel_frequency
  FROM `modulabs_project.data`
  WHERE CustomerID IS NOT NULL
  GROUP BY CustomerID
)

SELECT
  u.*,
  t.total_transactions,
  t.cancel_frequency,
  ROUND(t.cancel_frequency / t.total_transactions, 2) AS cancel_rate
FROM `modulabs_project.user_data` AS u
LEFT JOIN TransactionInfo AS t
ON u.CustomerID = t.CustomerID;
```

total_transac...	cancel_frequ...	cancel_rate
2	1	0.5
2	1	0.5
182	0	0.0
182	0	0.0
182	0	0.0
182	0	0.0

- 다양한 컬럼들을 활용하여 고객의 구매 패턴과 선호도를 보다 심층적으로 이해할 수 있도록 최종적으로 **user_data** 를 출력하기

```
SELECT *
FROM `modulabs_project.user_data`;
```

	A	B	C	D	E	F	G	H	I	J	K
	InvoiceNo	StockCode	Quantity	InvoiceDate	UnitPrice	CustomerID	Country	Description	total_transactions	cancel_frequency	cancel_rate
1	541431	23166	74215	2011-01-18 10:01:00.000000 UTC	1.04	12346	United Kingdom	MEDIUM CERAMIC TOP STORAGE JAR	2	1	0.5
2	541433	23166	74215	2011-01-18 10:17:00.000000 UTC	1.04	12346	United Kingdom	MEDIUM CERAMIC TOP STORAGE JAR	2	1	0.5
3	537626	22771	12	2010-12-07 14:57:00.000000 UTC	1.25	12347	Iceland	CLEAR DRAWER KNOB ACRYLIC EDWARDIAN	182	0	0
4	537626	852320	3	2010-12-07 14:57:00.000000 UTC	4.95	12347	Iceland	SET/3 DECOURAGE STACKING TINS	182	0	0
5	537626	22774	12	2010-12-07 14:57:00.000000 UTC	1.25	12347	Iceland	RED DRAWER KNOB ACRYLIC EDWARDIAN	182	0	0
6	537626	22727	4	2010-12-07 14:57:00.000000 UTC	3.75	12347	Iceland	ALARM CLOCK BAKELIKE RED	182	0	0
7	537626	85116	12	2010-12-07 14:57:00.000000 UTC	2.1	12347	Iceland	BLACK CANDELABRA T-LIGHT HOLDER	182	0	0
8	537626	22212	6	2010-12-07 14:57:00.000000 UTC	2.1	12347	Iceland	FOUR HOOK WHITE LOVEBIRDS	182	0	0

회고

[회고 내용을 작성해주세요]

Keep : 빅데이터를 통해 테이블들을 생성하고 변환하여 sql 데이터 전체 흐름을 이해한 점

Problem : 구체적으로 어떻게 작성해야하는지 잘 모르거나 헷갈리던 점들이 존재했음

Try : 콤마같은 것 빼먹지 않는 습관 들이기, sql 더 잘 알고 더 잘 할 수 있도록 노력하기